

## AIR-SARShip-1.0: 高分辨率SAR舰船检测数据集

孙显<sup>\*①②③</sup> 王智睿<sup>①③</sup> 孙元睿<sup>①②</sup> 刁文辉<sup>①③</sup> 张跃<sup>①③</sup> 付琨<sup>①②③</sup>

<sup>①</sup>(中国科学院空天信息创新研究院 北京 100190)

<sup>②</sup>(中国科学院大学 北京 100190)

<sup>③</sup>(中国科学院网络信息体系技术创新重点实验室 北京 100190)

**摘要:** 近年来,深度学习技术得到广泛应用,然而在合成孔径雷达(SAR)舰船目标检测研究中,由于数据获取难、样本规模小,尚难以支撑深度网络模型的训练。该文公开了一个面向高分辨率、大尺寸场景的SAR舰船检测数据集,该数据集包含31景高分三号SAR图像,场景类型包含港口、岛礁、不同级别海况的海面等,背景涵盖近岸和远海等多样场景。同时,该文使用经典舰船检测算法和深度学习算法进行了实验,其中基于密集连接端到端网络方法效果最佳,平均精度达到88.1%。通过实验对比分析形成指标基准,方便其他学者在此数据集基础上进一步展开SAR舰船检测相关研究。

**关键词:** SAR舰船检测; 公开数据集; 深度学习

中图分类号: TN957.51; TN958

文献标识码: A

文章编号: 2095-283X(2019)06-0852-11

DOI: [10.12000/JR19097](https://doi.org/10.12000/JR19097)

**引用格式:** 孙显, 王智睿, 孙元睿, 等. AIR-SARShip-1.0: 高分辨率SAR舰船检测数据集[J]. 雷达学报, 2019, 8(6): 852–862. doi: 10.12000/JR19097.

**Reference format:** SUN Xian, WANG Zhirui, SUN Yuanrui, et al. AIR-SARShip-1.0: High-resolution SAR ship detection dataset[J]. *Journal of Radars*, 2019, 8(6): 852–862. doi: 10.12000/JR19097.

## AIR-SARShip-1.0: High-resolution SAR Ship Detection Dataset

SUN Xian<sup>\*①②③</sup> WANG Zhirui<sup>①③</sup> SUN Yuanrui<sup>①②</sup> DIAO Wenhui<sup>①③</sup>  
ZHANG Yue<sup>①③</sup> FU Kun<sup>①②③</sup>

<sup>①</sup>(Aerospace Information Research Institute, Chinese Academy of Sciences, Beijing 100190, China)

<sup>②</sup>(University of Chinese Academy of Sciences, Beijing 100190, China)

<sup>③</sup>(Key Laboratory of Network Information System Technology(NIST), Aerospace Information Research Institute, Chinese Academy of Sciences, Beijing 100190, China)

**Abstract:** Over the recent years, deep-learning technology has been widely used. However, in research based on Synthetic Aperture Radar (SAR) ship target detection, it is difficult to support the training of a deep-learning network model because of the difficulty in data acquisition and the small scale of the samples. This paper provides a SAR ship detection dataset with a high resolution and large-scale images. This dataset comprises 31 images from Gaofen-3 satellite SAR images, including harbors, islands, reefs, and the sea surface in different conditions. The backgrounds include various scenarios such as the near shore and open sea. We conducted experiments using both traditional detection algorithms and deep-learning algorithms and observed the densely connected end-to-end neural network to achieve the highest average precision of 88.1%. Based on the experiments and performance analysis, corresponding benchmarks are provided as a basis for further research on SAR ship detection using this dataset.

**Key words:** SAR ship detection; Public dataset; Deep learning

收稿日期: 2019-11-16; 改回日期: 2019-12-17; 网络出版: 2019-12-27

\*通信作者: 孙显 sunxian@mail.ie.ac.cn \*Corresponding Author: SUN Xian, sunxian@mail.ie.ac.cn

基金项目: 国家自然科学基金(61725105, 41801349, 41701508), 国家高分辨率对地观测系统重大专项(GFZX0404120405)

Foundation Items: The National Natural Science Foundation of China (61725105, 41801349, 41701508), National Major Project on High Resolution Earth Observation System (GFZX0404120405)

责任编辑: 张增辉 Corresponding Editor: ZHANG Zenghui

## 1 引言

合成孔径雷达(Synthetic Aperture Radar, SAR)是一种主动式微波成像雷达, 它具备全天时、全天候的观测能力, 在军事和民用领域中具有广阔的应用前景。近几年来, 随着我国对地观测技术的进步, 高分三号等多颗高分辨率SAR成像卫星陆续投入使用, SAR数据的质量和数量得到持续提升。

SAR图像解译一直面临较大的挑战。SAR成像和光学成像差别较大, 表征不直观, 且成像时存在的相干斑、叠掩等现象容易对目标判读产生干扰。现有日常作业中大多采用人工解译, 费时费力, 难以满足海量SAR图像实时解译的需求。

港口及海上区域的舰船目标持续监测是一项重要的应用任务<sup>[1]</sup>。舰船目标的提取和检测也一直是SAR图像解译领域的研究热点。SAR舰船检测分为近岸舰船检测和远海舰船检测两类。一般情况下, 远海舰船中背景相对单一, 前景目标提取任务难度略低; 而近岸区域舰船数量较多, 种类更为丰富, 但由于港口处于海陆分割区域, 受背景噪声干扰、地物类型多变等影响, 对目标提取和识别的难度较大。

经典的舰船检测方法主要是将统计学习与恒虚警率(Constant False Alarm Rate, CFAR)方法相结合。在针对单极化SAR的舰船目标检测研究中, Rey<sup>[2]</sup>最早提出利用K分布海杂波模型结合CFAR的检测方法, Novak等人<sup>[3]</sup>则发展了利用高斯模型的双参数CFAR的方法, D. Stagliano等人<sup>[4]</sup>也提出了一种基于CFAR与小波变换联合的SAR图像舰船目标检测算法。Jinglu He等人<sup>[5]</sup>进一步提出了一种基于超像素级局部信息测量的极化SAR舰船自动检测方法, 通过生成多尺度超像素来计算某一超像素与周围像素间的测量值, 将不同度量从超像素级转换为像素级进行判别和分类检测。传统方法虽然已经广泛地应用在舰船检测中, 但其比较依赖于人工设计特征分类器提取舰船特征, 比如CFAR算法的性能依赖于对海洋杂波的建模。同时, 考虑到人工设计的特征分类器往往不能充分区别舰船和岛礁、近岸人造设施等虚警目标, 因此往往在背景相对单一的远海舰船检测中效果较好, 而在背景复杂的近岸舰船检测中效果并不理想。

近年来, 随着深度学习方法逐步发展, 已出现了许多使用深度神经网络模型的目标检测算法, 在一定程度上改善了传统学习方法的不足。常用的网络模型包括自动编码器、玻尔兹曼机以及卷积神经网络。尤其是卷积神经网络, 相继出现了Alex Network (AlexNet), VGG, Google Network (GoogleNet)和残差网络(Residual Network, Res-

Net)等基础网络, 及以此为结构的众多目标检测模型, 包括SSD, YOLOv1和Faster-RCNN(Faster-Region Convolutional Neural Networks)等, 这些方法在SAR舰船检测领域中也逐渐成为主流。

然而, 深度学习方法往往需要大量的训练样本数据作为支撑。在计算机视觉领域, 已有较多的公开样本数据集, 如ImageNet<sup>[6]</sup>, VOC<sup>[7]</sup>, COCO<sup>[8]</sup>等, 数据规模达上千类目标、百万级切片。最近两年, 在光学遥感领域, 也有DOTA<sup>[9]</sup>, HRRSD<sup>[10]</sup>, RSOD<sup>[11,12]</sup>等数据集先后公开, 为众多算法的研究测试提供了便利。

相比之下, SAR图像舰船检测领域现有的公开数据集较为有限, 可见公开报道的主要有SSDD<sup>[13]</sup>, OpenSARShip<sup>[14]</sup>以及文献[15]所提供的数据集。这3类数据集均以民用舰船目标的切片为主, 切片尺寸一般为 $256 \times 256$ 像素, 分辨率包括3 m, 5 m, 8 m, 10 m和20 m等, 背景相对单一, 远海背景为主, 近岸背景较少。这3个数据集发布后, 较好地促进了深度神经网络模型在SAR舰船检测中的应用, 同时也基于主流深度学习算法定义了数据集的指标基准。

事实上, 卫星应用中的舰船检测往往是在整景图像上处理的, 覆盖面积一般为数十平方公里甚至更大。这种条件下, 目标周围的环境, 如码头、道路、附属建筑, 甚至海浪等对舰船检测性能也有较大的影响。尤其是在近岸和有岛礁的场景中。因此, 一个包含远海与近岸等更真实、更多样的场景、涵盖多种类型舰船目标的数据集将有利于训练出性能更优、鲁棒性更强、实用性更高的SAR舰船检测模型。

为了促进SAR舰船检测方面的研究、提升国产化数据的使用率, 本文基于高分三号卫星数据, 构建了一个面向宽幅场景的SAR舰船目标公开样本数据集, 命名为AIR-SARShip-1.0。该数据集包含31景SAR图像, 场景类型包含港口、岛礁、不同级别海况的海面等, 标注信息主要为舰船目标的位置, 并经过专业判读人员的确认, 目前该数据集以支持复杂场景下的舰船目标检测等应用为主。该数据集已可通过《雷达学报》官网的相关链接(<http://radars.ie.ac.cn/web/data/getData?dataType=SARDataset>)免费下载使用。另外, 文中还使用几种常见深度学习网络进行了比较实验与分析, 形成该数据集SAR舰船检测性能指标的基准, 便于其他学者以此为参考展开相关研究。

## 2 AIR-SARShip-1.0样本数据集信息

### 2.1 基础信息

高分三号卫星是国家高分辨率对地观测系统重

大专项中的民用微波遥感成像卫星，也是我国首颗C频段多极化高分辨率合成孔径雷达卫星<sup>[16]</sup>。本文公开的AIR-SARShip-1.0数据集均来源于高分三号卫星，包含31景大图，数据集信息如表1所示，图像分辨率包括1 m和3 m，成像模式包括聚束式和条带式，极化方式为单极化，图像格式为Tiff，图像尺寸绝大多数为3000×3000像素，本文列出了数据集中每一幅图像的详细信息，包括图像编号、像素尺寸、分辨率、海况、场景以及舰船数量，详细信息如文后附表1所示。

表 1 数据集信息

Tab. 1 The dataset information

分辨率	成像模式	极化方式	图像格式
1 m, 3 m	聚束式、条带式	单极化	Tiff

## 2.2 标注信息

AIR-SARShip-1.0数据集按照PASCAL VOC数据集格式标注，结果保存文件为XML格式。图1(a)展示了数据集中某幅图像的舰船标注样例，图1(b)所示为XML文件中一个目标的标注示例，该文件中实际包含图1(a)中所有舰船目标的矩形框信息，图1(b)中仅仅列出其中一个目标的矩形框信息。XML文件中包含对应图像文件名、图像像素大小、图像通道数、图像分辨率、每个目标的类别名称以及目标框的位置。以图像左上角点位坐标原点，每个目标所在区域按矩形框标注，依次包括矩形框X轴坐标的最小值(xmin)与最大值(xmax)、Y轴坐标的最小值(ymin)与最大值(ymax)4个坐标点，坐标值即为矩形框在图像中实际像素的位置，标注文件的格式跟VOC数据集中标注文件的格式保持一致。图2中则展示了该数据集的典型场景示

例，可以发现图像不仅包含众多的舰船信息，还包括周围海域、陆地及港口相关信息，更加贴近实际舰船检测应用。

实际训练过程中存在训练集与测试集的分配问题，考虑本数据集中包含共31景大图，一般建议按照大约2:1的比例，将21景图像作为训练数据，其余10景图像作为测试数据。矩形框的面积分布图如图3所示，图中横轴代表矩形框的面积所属区间，纵轴代表该面积范围内舰船数量占总数量的比重，例如第1个柱状条代表有6%的舰船矩形框面积在1000以下，第2个柱状条代表有13%的舰船矩形框面积在1000到2000之间。鉴于每张大图的尺寸是3000×3000像素，从图3可以看出大多数目标矩形框都分布于2000~5000，在整张大图中占比例较小，即使把整张大图做出500×500像素的切片，舰船矩形框在切片中的占比也仅仅在0.008~0.020，因此该数据集的场景大、目标小的特性十分显著。对比视觉领域中最具挑战性的数据集之一COCO，其小目标的比例也仅为41%，因此，AIR-SARShip-1.0数据集重点考验算法模型对小目标的检测性能。

## 3 对比模型

### 3.1 传统舰船检测算法

在深度学习流行之前，各国研究者对SAR舰船检测领域进行了深入研究，提出了许多经典SAR舰船检测算法，如CFAR算法、最佳熵自动门限法(Kapur, Sahoo and Wong, KSW)、基于K分布的CFAR方法等。最佳熵自动门限法将信息论中Shannon熵概念用于图像分割，其出发点是使图像中目标与背景分布的信息量最大。该算法通过选取双阈值克服了单阈值分割算法对高分辨率图像存在的舰船检测不连通、检测虚警高等问题。CFAR检

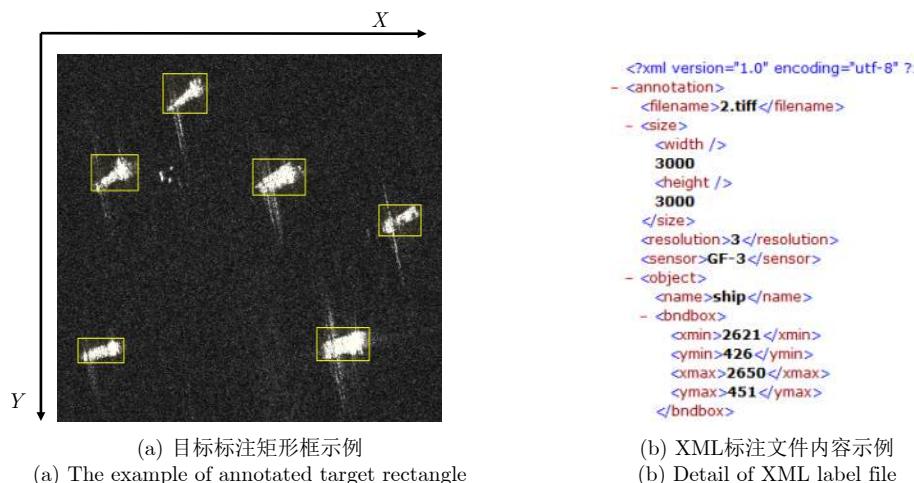


图 1 数据集标注示意图

Fig. 1 The annotated example in the dataset

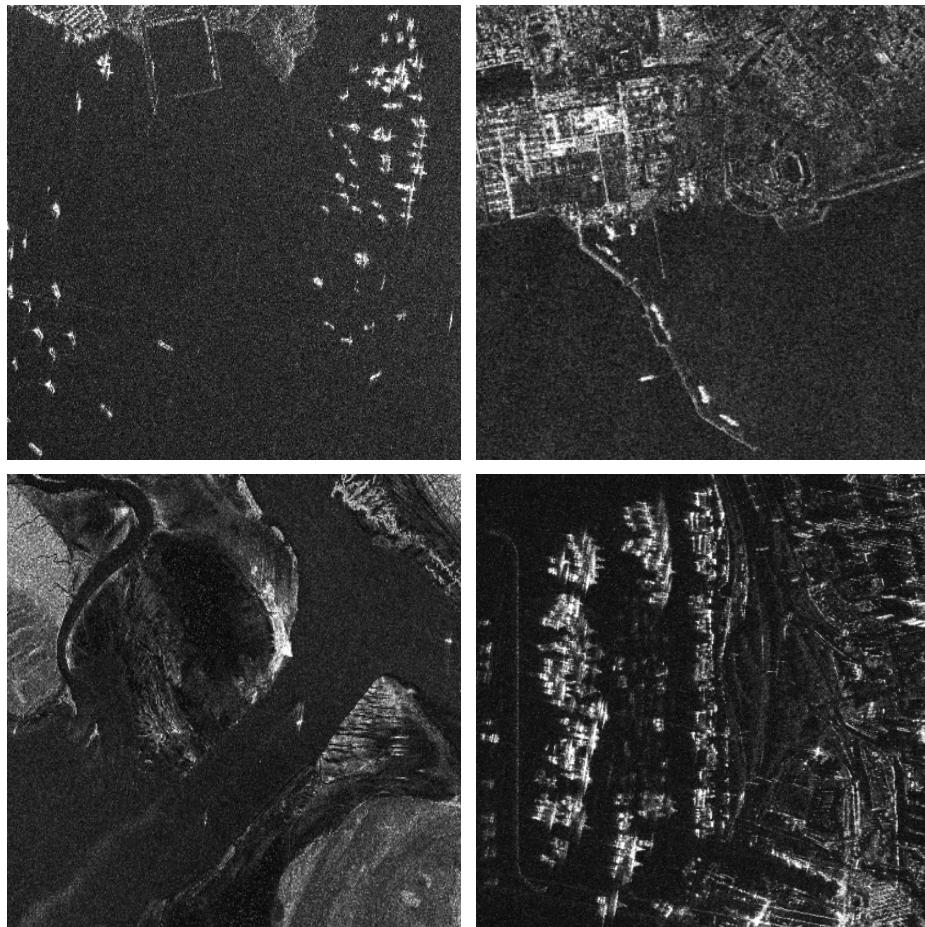


图 2 AIR-SARShip-1.0数据集中场景示例

Fig. 2 The example scenes of AIR-SARShip-1.0 dataset

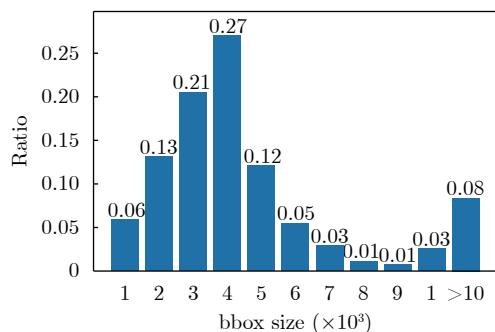


图 3 数据集舰船矩形框面积分布

Fig. 3 The area distribution of ship rectangle in the dataset

测方法是雷达信号检测领域里最常用和最有效的检测算法之一，这个算法的核心思想是在保证虚警率为常数的同时，根据虚警率和SAR图像海洋杂波的统计特性(即海洋杂波的概率密度函数)计算得到检测舰船目标的阈值。当以高斯模型建立海洋背景杂波模型时，可以得到双参数CFAR算法，但是在很多情况下，高斯模型对海洋杂波的描述并不理想，所以1976年Jakeman和Pusey引入K分布的概念用来描述海洋杂波，即基于K分布的CFAR方法，进

一步提升了舰船检测的精度，得到普遍认可。本文实验部分将利用3种经典舰船检测算法在AIR-SARShip-1.0数据集上进行测试与分析。

### 3.2 视觉领域目标检测算法

近些年来，随着深度学习技术的发展，视觉领域的目标检测问题也涌现出诸多算法，主要分为两大类：单阶段目标检测器和双阶段目标检测器。单阶段代表算法有SSD<sup>[17]</sup>, YOLOv1<sup>[18]</sup>, RetinaNet<sup>[19]</sup>等，单阶段检测算法YOLOv1只包含2个部分：特征提取部分以及检测目标框部分，YOLOv1将图像划分为 $S \times S$ 个网格，每个物体所在网格中心负责预测目标框位置以及类别，且仅能预测单类物体。SSD与YOLOv1不同点在于，SSD添加了锚框以及多尺度特征提取层，改善了YOLOv1网格粗糙、对小目标检测精度差的缺点。双阶段代表算法有R-CNN<sup>[20]</sup>, Fast-RCNN<sup>[21]</sup>, Faster-RCNN<sup>[22]</sup>, FPN(Feature Pyramid Networks)<sup>[23]</sup>等，其中最具有代表性的是Faster-RCNN，该算法包含3个部分：第1部分为基础网络，从图像提取高层特征；第2部分为区域生成网络(Region Proposal Network，

RPN), 提出可能为目标的候选框; 最后一部分为预测框回归网络, 基于候选框对目标做进一步分类及位置回归。由于双阶段检测网络有候选框提取部分, 所以在控制正负样本比例以及后续更精细化调节候选框的位置上要优于单阶段检测网络, 但同时也大大增加了检测的时间成本。

上述视觉领域的目标检测算法都有相似的基础网络, 例如VGG, ResNet等。VGG主要分为卷积网络和全连接网络两部分。ResNet主要用于解决随着网络深度增加而导致网络性能下降的问题, 它巧妙地设计了跳接模块组成残差块, 大大加深了可使用的网络深度, 常用的ResNet网络包括ResNet50, ResNet101, ResNet152。

### 3.3 基于密集旋转增强的Faster-RCNN检测算法

目前, 在数据增强中主要使用的手段有图像翻转、随机缩放以及旋转, 其中图像旋转主要是做 $90^{\circ}$ 旋转, 而SAR卫星经常会对同一个地点做多时相以及多角度的成像, 但这个角度是不确定的, 既不是 $90^{\circ}$ 旋转也不是 $180^{\circ}$ 的翻转, 如图4所示, 这两幅SAR图像近似在同一地点成像, 但是成像角度有一定差异。SAR成像不同于光学成像, 不同角度的成像结果差异较大<sup>[24]</sup>, 如果只使用旋转 $90^{\circ}$ 的数据增强方式检测性能提升很有限。为了解决这一问题, 本文中采用小角度间隔密集旋转增强的Faster-RCNN检测方法(Faster-RCNN based on Dense Rotation, Faster-RCNN-DR), 以求获得数据角度的多样性, 从而进一步提升SAR舰船目标检测的性能。图5展示了原图和逆时针旋转 $20^{\circ}$ ,  $40^{\circ}$ 和 $60^{\circ}$ 之后的图像。

### 3.4 基于密集连接端到端网络的检测算法

根据应用场景和成像模式的不同, SAR图像的分辨率具有多样性, 同一舰船目标在不同分辨率图像中、不同舰船目标在相同分辨率图像中会呈现出大小不一的特点, 多分辨率SAR影像中舰船多尺度

特性给目标检测带来了较大的挑战。在深度卷积神经网络中, 低层卷积层的特征图含有丰富的空间信息, 但是语义信息较少, 高层的特征图含有较多的语义信息但是空间信息较少, 而且尺度较小的目标经过多层卷积之后留下的信息很少, 不利于对小目标检测与识别。因此, 为了解决不同分辨率SAR图像多尺度舰船目标的检测难题, 文献[25]提出了一种基于密集连接端到端网络结构(Dense Connected End-to-end Neural Network, DCENN)的舰船检测算法。该网络的主要结构如图6所示, 使用ResNet101作为基础网络, 图像经过多次卷积之后, 随着卷积网络的加深, 特征图有越来越多的语义信息, 但是分辨率越来越低。为了使高分辨率的特征图同时拥有高层特征图的语义信息, 可将高层特征图与低层特征图进行如图7所示的迭代连接。在基础网络和RPN网络之后是二阶段的检测子网络(如图6虚线框内所示), 它具体分为候选区池化部分和用于分类和回归的全连接层部分, 通过对这两部分进行了轻量化改进处理, 既保证了检测精度又降低了内存占用、提升了处理速度。

## 4 实验结果分析

为了验证深度学习方法相比传统方法的优越性, 本文在AIR-SARship-1.0数据集上做了实验, 比较第3部分中提到的几种算法的舰船检测性能, 并给出具体分析。实验机器的操作系统为Ubuntu 16.04, 内存32 GB, CPU使用Intel Xeon E5-2630, 深度学习算法使用到的显卡是NVIDIA Tesla P100, 传统算法没有使用显卡加速, 只使用CPU进行计算。将数据集分为测试数据和训练数据, 其中训练数据为21景大图, 测试数据为10景大图, 数据集中会提供train.txt和test.txt的文件详细记录训练集和测试集的文件名。在CFAR算法中认为海洋杂波服从 $(0, 1)$ 的高斯分布; 在基于K分布的CFAR算法

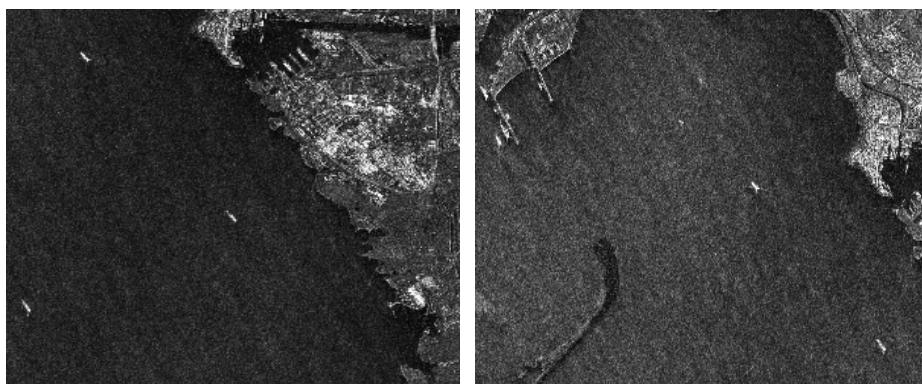


图 4 同一地区不同角度成像示例

Fig. 4 Imaging examples of the same area at different angles

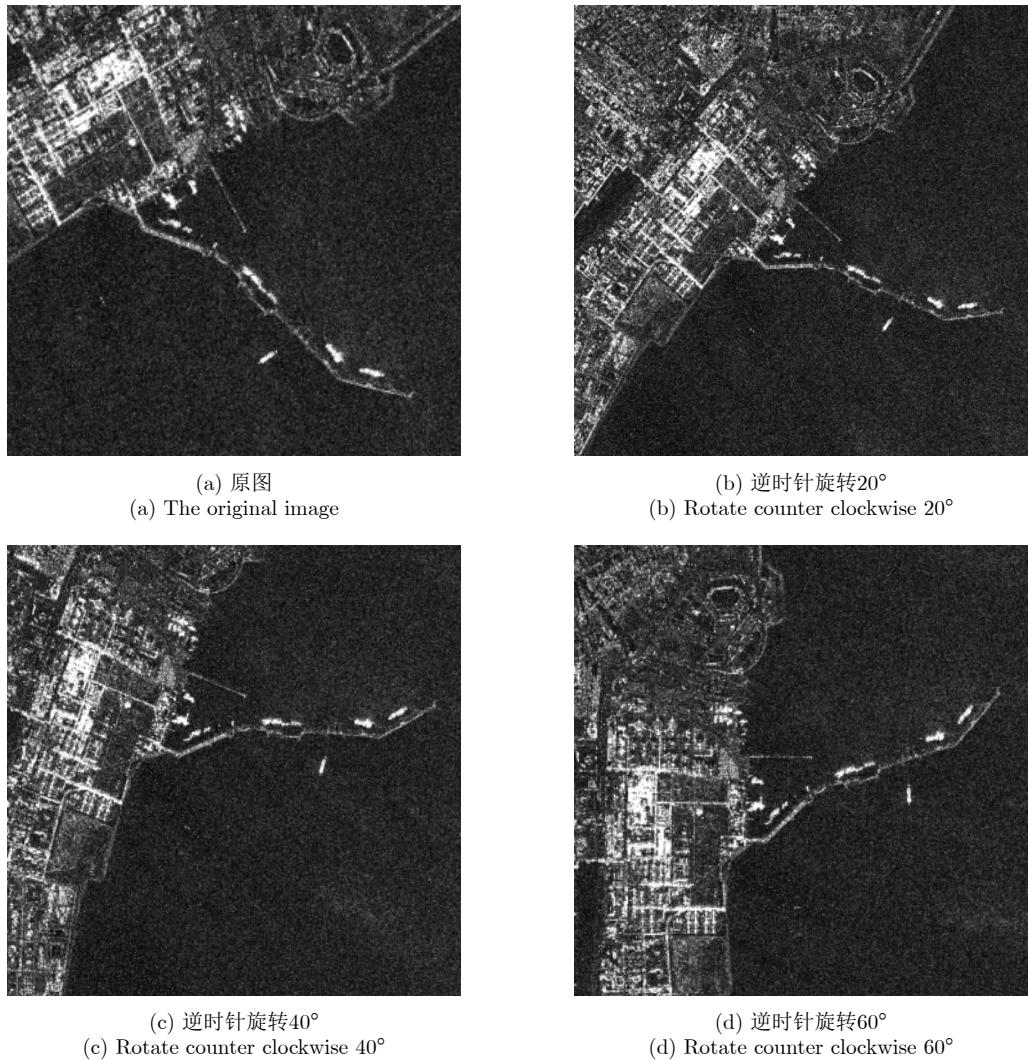


图 5 旋转图像示例

Fig. 5 The examples of rotated images

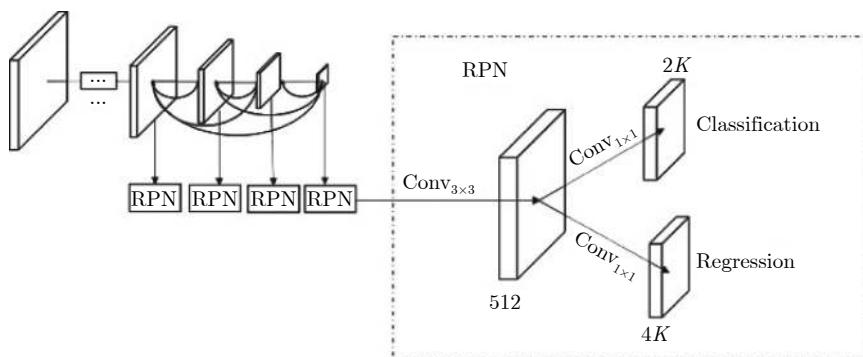


图 6 DCENN网络主要结构

Fig. 6 The main structure of DCENN network

中, 设置参数 $K=2$ ; 在最佳熵自动门限法中, 根据数据图像自动选择最佳阈值参数。由于传统算法不需要训练数据, 故直接使用测试集数据集进行试验, 测试精度如表2所示。

其中AP计算方式如式(1)所示

$$AP = \sum_0^1 (r_{n+1} - r_n) p_{\text{interp}}(r_{n+1}) \quad (1)$$

其中 $p_{\text{interp}}(r_{n+1})$ 计算方式如式(2)所示

$$p_{\text{interp}}(r_{n+1}) = \max_{\tilde{r}: \tilde{r} \geq r_{n+1}} p(\tilde{r}) \quad (2)$$

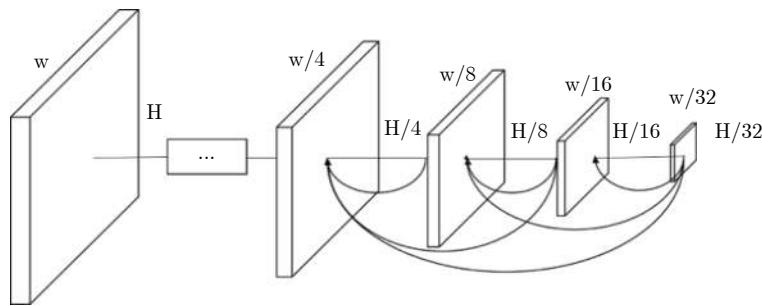


图 7 基于密集连接融合特征图

Fig. 7 The fusion feature map based on dense connection

其中,  $p(\tilde{r})$  代表在召回率  $\tilde{r}$  下最大的准确率, 准确率  $p$  和召回率  $r$  的计算式如(3)和式(4)所示

$$p = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (3)$$

$$r = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (4)$$

其中, TP 代表检测结果为真且真值为真的检测框数量, FP 代表检测结果为真但真值为假的检测框数量, FN 代表检测结果为假但真值为真的检测框数量。如式(5)所示

$$\text{IOU} = \frac{\text{area}(B_p \cap B_{gt})}{\text{area}(B_p \cup B_{gt})} \quad (5)$$

定义交并比 IOU 为检测框与标注框重合部分面积除以两者做并集部分的面积, 当 IOU 大于 0.5 认为检测成功, 记为 TP, 当 IOU 小于 0.5 认为是虚警, 记为 FP, 然后未检测出的舰船记为 FN。由于本数据集只包含舰船一类, 所以代表所有类的 AP 平均值 mAP 与 AP 值相同。

视觉领域的深度学习目标检测算法 SSD, YOLOv1 和 Faster-RCNN 以及基于旋转增强的检测网络算法均使用开源框架 Pytorch 进行实验, 焦娇等人的 DCENN 算法使用 Tensorflow 开源框架进行实验。在实验过程中, 将大图切成  $500 \times 500$  像素尺寸大小, 然后使用图像翻转、图像旋转、对比度增强和随机缩放等方式做数据增强, 其中 Faster-RCNN, SSD-512, SSD-300, YOLOv1 几种算法使用的训练集是经过  $90^\circ$  旋转增强的, 而基于 Faster-RCNN 的旋转增强算法使用的训练集是经过以  $10^\circ$  为间隔密

集旋转增强的。在 SSD 中使用了两种图像尺寸, SSD-300 和 SSD-512。实验中设置学习率为 0.00001, 动量设置为 0.99, 根据 GPU 的内存限制, 设置 SSD-300 的批处理量为 24, SSD-512 为 4, Faster-RCNN 为 12, DCENN 算法 [25] 设置为 1, 其它超参数均设置相同如文献 [22], 基于旋转增强的检测网络算法中超参数设置与 Faster-RCNN 完全相同。

各深度学习算法的舰船检测性能如表 3 所示, 其中每种算法的运行速度用 FPS 衡量, FPS 代表每秒该算法可检测的图像张数, 其中 DCENN, Faster-RCNN-DR, Faster-RCNN, YOLOv1 这几种算法输入的测试图像尺寸为  $500 \times 500$ , SSD-512 输入测试图像尺寸为  $512 \times 512$ , SSD-300 输入测试图像尺寸为  $300 \times 300$ 。从表中可以看出, 使用  $90^\circ$  旋转训练集增强的算法中, YOLOv1 的指标最低, 运行速度最快, 而文献 [25] 提出的 SAR 舰船检测算法性能最优, 运行速度最慢。在单阶段目标检测算法中, YOLOv1 没有使用锚框进行预测, 而是将图像划分为  $S \times S$  个网格, 每个网格只能预测一个目标, 所以 YOLOv1 在 AIR-SARShip-1.0 这种密集小目标较多的数据集中检测性能较差, 但也正因为去除锚框, 使得 YOLOv1 的运行速度最快; SSD 在训练时加入锚框, 而且在网络多个特征层中进行预测, 弥补了 YOLOv1 的不足, 检测性能有所提升, 但运行时间稍慢于 YOLOv1; Faster-RCNN 作为典型的双阶段检测算法, 使用 RPN 网络提出候选框使得后

表 3 基于深度学习的 SAR 舰船检测算法的性能基准

Tab. 3 The performance benchmarks of SAR ship detection algorithms based on deep learning

算法	AP(%)
CFAR	27.1
基于 $K$ 分布的 CFAR	19.2
KSW	28.2

性能排名	算法	AP(%)	FPS
1	DCENN	88.1	24
2	Faster-RCNN-DR	84.2	29
3	Faster-RCNN	79.3	30
4	SSD-512	74.3	64
5	SSD-300	72.4	151
6	YOLOv1	64.7	160

面检测网络更精确的回归目标框的位置, 性能优于单阶段检测算法, 同时拥有双阶段算法的缺点, 运行速度明显慢于单阶段算法。同样是使用Faster-RCNN检测算法, Faster-RCNN-DR以 $10^\circ$ 为间隔的密集旋转数据增强方法比 $90^\circ$ 旋转增强方法在性能上提升了4.9%, 这是因为密集旋转的方式在一定程度上提升了数据集的丰富性和角度多样性, 因为没有在网络阶段做出额外工作因此与Faster-RCNN检测算法运行时间基本相同。DCENN舰船检测算法中因为使用了密集连接, 并且在多个特征层上进行预测, 能更好地提取舰船特征, 所以算法的性能最高, 而密集连接也带来了更高的计算量, 使得算法运行时间最长。

表4给出了3种代表性算法在近岸和远海两种不同场景的检测结果, 可以发现, 远海场景的检测精度明显高于近岸场景, 在本数据集上的最高精度优于95%, 而近岸场景的性能则降低20%以上。这符合远海场景背景相对单一、噪声较少, 而近岸场景受码头、建筑物、陆地等干扰较多的实际情况, 也

表 4 不同场景下算法性能结果

Tab. 4 The performance benchmarks of different scenes based on different algorithms

性能排名	算法	近岸舰船AP(%)	远海舰船AP(%)
1	DCENN	68.1	96.3
2	Faster-RCNN-DR	57.6	94.6
3	SSD-512	40.3	89.4

在一定程度上表明, 近岸舰船目标检测距离实用仍有较大差距, 是一个具有挑战性的研究课题。

为了更直观地展示算法在AIR-SARShip-1.0数据集的检测效果, 以某一景大图为例, 使用Faster-RCNN算法进行舰船目标检测, 结果如图8所示, 绿色框中数字代表检测框的置信度。从图中可以看出, 绝大多数舰船目标均正确检测出(图8c), 检测框与目标重合度较好(图8c)、有一定差距且存在虚警(图8a)、检测框重合度稍差(图8b)、少数舰船漏检(图8d)。总体而言, 检测结果还存在不理想情况, 性能有待进一步提升。

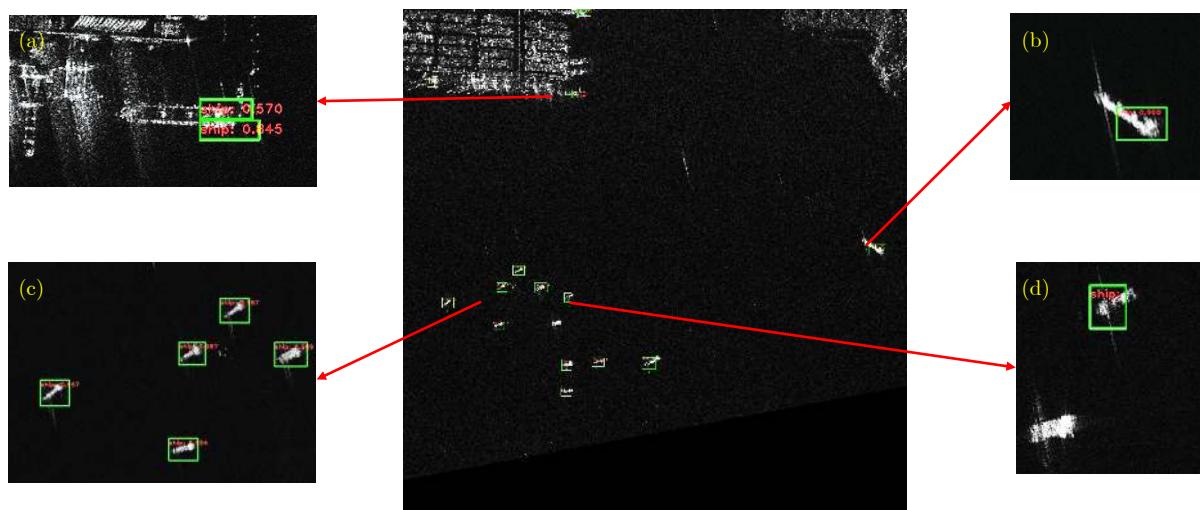


图 8 基于Faster-RCNN的SAR舰船检测示意图

Fig. 8 The detection example of SAR ship based on Faster-RCNN

## 5 结束语

为了促进深度学习技术在SAR舰船检测领域中的应用, 本文公开了一个大场景、高分辨的AIR-SARShip-1.0数据集, 该数据集包括近岸、远海两种场景。本文使用传统舰船检测算法及常见的深度学习检测算法进行了实验, 结果发现: 深度学习算法的检测性能明显优于传统舰船算法, 其中DCENN检测算法在密集连接网络结构的基础上使用多个特征层进行预测, 舰船检测AP指标最高, 但运行速

度最慢。其次, 使用密集角度旋转的数据扩充方式可以在一定程度上提升数据的角度多样性, 有利于模型性能提升且不会对预测时带来额外的运算。另外, 文中分别在近岸和远海两种场景下测试了不同算法的性能, 其中各算法在远海场景中性能差异较小, 而在近岸场景中差异较大, 这说明近岸环境更加复杂、舰船检测面临的挑战更加严峻。实验结果为AIR-SARShip-1.0数据集构建了性能基准, 方便其他学者进一步展开SAR舰船检测的相关研究。

## 附录

高分辨率SAR舰船检测数据集-1.0(AIR-SARShip-1.0)依托《雷达学报》官方网站发布,现已上传至学报网站“数据”版块“SAR样本数据集”,网址为:<http://radars.ie.ac.cn/web/data/getData?dataType=SARDataset>,如附图1所示。

AIR-SARShip-1.0数据集依托国家高分辨率对地观测系统重大科技专项,构建一套面向宽幅场景、覆盖典型类型、贴近实际应用的舰船目标数据集,旨在进一步提高国产化数据使用率,推动SAR目标检测等先进技术的深入研究。该数据集所有权归国家高分辨率对地观测系统重大科技专项和中国科学院空天信息创新研究院所有,《雷达学报》编辑部具有编辑出版权等。



附图 1 AIR-SARShip-1.0数据集发布地址  
App. Fig. 1 Release address of AIR-SARShip-1.0 dataset

附表 1 AIR-SARShip-1.0数据集详情  
App. Tab. 1 AIR-SARShip-1.0 dataset information in detail

图像编号	像素尺寸	海况	场景	分辨率(m)	舰船数量
1	3000×3000	2级	近岸	3	5
2	3000×3000	0级	近岸	1	7
3	3000×3000	3级	远海	3	10
4	3000×3000	2级	远海	3	8
5	3000×3000	1级	近岸	3	15
6	3000×3000	4级	远海	3	3
7	3000×3000	4级	远海	3	5
8	3000×3000	1级	近岸	1	2
9	3000×3000	2级	近岸	1	7
10	3000×3000	1级	远海	1	50
11	3000×3000	1级	近岸	1	80
12	3000×3000	2级	近岸	1	18
13	4140×4140	1级	近岸	1	21
14	3000×3000	1级	近岸	1	15
15	3000×3000	1级	近岸	1	77
16	3000×3000	3级	近岸	3	13
17	3000×3000	3级	近岸	3	3
18	3000×3000	3级	近岸	3	2
19	3000×3000	3级	近岸	3	1
20	3000×3000	2级	近岸	3	7

续表1

图像编号	像素尺寸	海况	场景	分辨率(m)	舰船数量
21	3000×3000	2级	近岸	3	9
22	3000×3000	1级	近岸	3	14
23	3000×3000	1级	远海	3	4
24	3000×3000	4级	远海	3	6
25	3000×3000	4级	远海	1	20
26	3000×3000	2级	近岸	3	15
27	3000×3000	2级	近岸	3	19
28	3000×3000	1级	近岸	3	8
29	3000×3000	3级	远海	3	6
30	3000×3000	2级	远海	3	8
31	3000×3000	1级	近岸	3	3

## 参 考 文 献

- [1] 张杰, 张晰, 范陈清, 等. 极化SAR在海洋探测中的应用与探讨[J]. 雷达学报, 2016, 5(6): 596–606. doi: [10.12000/JR16124](https://doi.org/10.12000/JR16124). ZHANG Jie, ZHANG Xi, FAN Chenqing, et al. Discussion on application of polarimetric synthetic aperture radar in marine surveillance[J]. *Journal of Radars*, 2016, 5(6): 596–606. doi: [10.12000/JR16124](https://doi.org/10.12000/JR16124).
- [2] REY M T, CAMPBELL J, and PETROVIC D. A comparison of ocean clutter distribution estimators for CFAR-based ship detection in RADARSAT imagery[R]. Technical Report No. 1340, 1998.
- [3] NOVAK L M, BURL M C, and IRVING W W. Optimal polarimetric processing for enhanced target detection[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 1993, 29(1): 234–244. doi: [10.1109/7.249129](https://doi.org/10.1109/7.249129).
- [4] STAGLIANO D, LUPIDI A, and BERIZZI F. Ship detection from SAR images based on CFAR and wavelet transform[C]. 2012 Tyrrhenian Workshop on Advances in Radar and Remote Sensing, Naples, Italy, 2012: 53–58.
- [5] HE Jinglu, WANG Yinghua, LIU Hongwei, et al. A novel automatic PolSAR ship detection method based on superpixel-level local information measurement[J]. *IEEE Geoscience and Remote Sensing Letters*, 2018, 15(3): 384–388. doi: [10.1109/LGRS.2017.2789204](https://doi.org/10.1109/LGRS.2017.2789204).
- [6] DENG Jia, DONG Wei, SOCHER R, et al. ImageNet: A large-scale hierarchical image database[C]. 2009 IEEE Conference on Computer Vision and Pattern Recognition, Miami, USA, 2009: 248–255.
- [7] EVERINGHAM M, VAN GOOL L, WILLIAMS C K I, et al. The PASCAL Visual Object Classes (VOC) challenge[J]. *International Journal of Computer Vision*, 2010, 88(2): 303–338. doi: [10.1007/s11263-009-0275-4](https://doi.org/10.1007/s11263-009-0275-4).
- [8] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context[C]. The 13th European Conference on Computer Vision, Zurich, Switzerland, 2014: 740–755.
- [9] XIA Guisong, BAI Xiang, DING Jian, et al. DOTA: A large-scale dataset for object detection in aerial images[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA, 2018: 3974–3983.
- [10] ZHANG Yuanlin, YUAN Yuan, FENG Yachuang, et al. Hierarchical and robust convolutional neural network for very high-resolution remote sensing object detection[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2019, 57(8): 5535–5548. doi: [10.1109/TGRS.2019.2900302](https://doi.org/10.1109/TGRS.2019.2900302).
- [11] LONG Yang, GONG Yiping, XIAO Zhifeng, et al. Accurate object localization in remote sensing images based on convolutional neural networks[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2017, 55(5): 2486–2498. doi: [10.1109/TGRS.2016.2645610](https://doi.org/10.1109/TGRS.2016.2645610).
- [12] XIAO Zhifeng, LIU Qing, TANG Gefu, et al. Elliptic Fourier transformation-based histograms of oriented gradients for rotationally invariant object detection in remote-sensing images[J]. *International Journal of Remote Sensing*, 2015, 36(2): 618–644. doi: [10.1080/01431161.2014.999881](https://doi.org/10.1080/01431161.2014.999881).
- [13] LI Jianwei, QU Changwen, and SHAO Jiaqi. Ship detection in SAR images based on an improved faster R-CNN[C]. 2017 SAR in Big Data Era: Models, Beijing, China, 2017: 1–6.
- [14] HUANG Lanqing, LIU Bin, LI Boying, et al. OpenSARShip: A dataset dedicated to Sentinel-1 ship interpretation[J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2018, 11(1): 195–208. doi: [10.1109/JSTARS.2017.2755672](https://doi.org/10.1109/JSTARS.2017.2755672).
- [15] WANG Yuanyuan, WANG Chao, ZHANG Hong, et al. A SAR dataset of ship detection for deep learning under complex backgrounds[J]. *Remote Sensing*, 2019, 11(7): 765. doi: [10.3390/rs11070765](https://doi.org/10.3390/rs11070765).

- [16] 张庆君. 高分三号卫星总体设计与关键技术[J]. 测绘学报, 2017, 46(3): 269–277. doi: [10.11947/j.AGCS.2017.20170049](https://doi.org/10.11947/j.AGCS.2017.20170049).  
ZHANG Qingjun. System design and key technologies of the GF-3 satellite[J]. *Acta Geodaetica et Cartographica Sinica*, 2017, 46(3): 269–277. doi: [10.11947/j.AGCS.2017.20170049](https://doi.org/10.11947/j.AGCS.2017.20170049).
- [17] LIU Wei, ANGUELOV D, ERHAN D, et al. SSD: Single shot MultiBox detector[C]. The 14th European Conference on Computer Vision, Amsterdam, The Netherlands, 2016: 21–37.
- [18] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA, 2016: 779–788.
- [19] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]. 2017 IEEE International Conference on Computer Vision, Venice, Italy, 2017: 2999–3007.
- [20] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. 2014 IEEE Conference on Computer Vision and Pattern Recognition, Columbus, USA, 2014: 580–587.
- [21] GIRSHICK R. Fast R-CNN[C]. 2015 IEEE International Conference on Computer Vision, Santiago, Chile, 2015: 1440–1448.
- [22] REN Shaoqing, HE Kaiming, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[C]. The 28th International Conference on Neural Information Processing Systems, Montreal, Canada, 2015: 91–99.
- [23] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]. 2017 IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, USA, 2017: 936–944.
- [24] LIU Peng and JIN Yaqiu. A study of ship rotation effects on SAR image[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2017, 55(6): 3132–3144. doi: [10.1109/TGRS.2017.2662038](https://doi.org/10.1109/TGRS.2017.2662038).
- [25] JIAO Jiao, ZHANG Yue, SUN Hao, et al. A densely connected end-to-end neural network for multiscale and multiscene SAR ship detection[J]. *IEEE Access*, 2018, 6: 20881–20892. doi: [10.1109/ACCESS.2018.2825376](https://doi.org/10.1109/ACCESS.2018.2825376).

### 作者简介



孙 显(1981–), 男, 中国科学院空天信息创新研究院研究员, 博士生导师, 主要研究方向为计算机视觉与遥感图像理解, IEEE高级会员, 雷达学报青年编委。  
E-mail: sunxian@mail.ie.ac.cn



王智睿(1990–), 男, 2018年在清华大学获得博士学位, 现任中国科学院空天信息创新研究院助理研究员, 主要研究方向为SAR图像智能解译。  
E-mail: zhirui1990@126.com



孙元睿(1995–), 男, 博士生, 2017年获得中国地质大学(武汉)工学学士学位, 现为中国科学院大学信息与通信工程博士生, 主要研究方向为SAR舰船检测。  
E-mail: sunyuanrui17@mails.ucas.ac.cn



刁文辉(1988–), 男, 2016年在中国科学院大学获得博士学位, 现任中国科学院空天信息创新研究院助理研究员。主要研究方向为深度学习理论及其在遥感图像解译中的应用, 目前已发表论文20余篇。  
E-mail: whdiao@mail.ie.ac.cn



张 跃(1990–), 男, 2017年在中国科学院大学获得博士学位, 现任中国科学院空天信息创新研究院助理研究员。主要研究方向为SAR图像智能分析与解译应用, 目前已发表SCI论文10余篇。  
E-mail: zhangyue@air.cas.ac.cn



付 琏(1974–), 男, 研究员, 博士生导师, 现任中国科学院空天信息创新研究院院长助理, 中国科学院重点实验室主任, 主要从事地理空间数据分析与挖掘、遥感图像智能解译等领域的研究工作, 先后获国家科技进步特等奖、国家科技进步一等奖和省部级一等奖等多项。  
E-mail: fukun@mail.ie.ac.cn